

Analyse des avis clients dans le tourisme avec Machine Learning explicable

Module: XAI & Gouvernance

Réaliser par :
Khadija BelBARAKA

Introduction :

Ce projet porte sur l'analyse des avis clients dans le domaine du tourisme. Les plateformes d'avis en ligne comme TripAdvisor sont devenues incontournables pour les voyageurs souhaitant choisir un hôtel, un restaurant ou une destination. Ces avis contiennent une mine d'informations précieuses sur ce que les clients apprécient ou critiquent. L'objectif de ce travail est d'exploiter ces données textuelles pour en extraire des connaissances utiles. La variable cible est la note attribuée par le client, qui varie de 1 à 5. Il s'agit donc d'un problème de classification multiclasse. Les objectifs de l'étude sont les suivants : analyser la répartition des notes, identifier les mots les plus fréquents dans les avis positifs et négatifs, comprendre les principaux facteurs de satisfaction et d'insatisfaction des clients dans le secteur touristique, et enfin proposer des recommandations aux professionnels du tourisme.

Présentation du dataset :

Le jeu de données utilisé provient de la plateforme TripAdvisor. Il s'agit d'un fichier CSV contenant 20 000 avis clients sur des hôtels. Le dataset est composé de deux colonnes : "Review" qui contient le texte de l'avis en anglais, et "Rating" qui contient la note attribuée par le client sur une échelle de 1 à 5. Aucune valeur manquante n'est présente dans le fichier. La distribution des notes est déséquilibrée : les notes 4 et 5 représentent environ 60% des avis, tandis que les notes 1 et 2 ne représentent qu'environ 21%. Ce déséquilibre est classique pour ce type de données, les clients satisfaits laissant plus facilement un avis que les clients insatisfaits.

Variable cible

La variable cible est "Rating" (note), qui est une note sur une échelle de 1 à 5 :

- 1 : Très mauvais
- 2 : Mauvais
- 3 : Moyen
- 4 : Bon
- 5 : Excellent

Nature du problème

Il s'agit d'un problème de classification multiclasse (5 classes correspondant aux 5 notes possibles).

Objectifs de l'étude

- Prédire la note d'un hôtel à partir du texte de l'avis client
- Identifier les facteurs (mots/phrases) qui influencent le plus la satisfaction client
- Comparer plusieurs modèles de Machine Learning pour ce problème
- Interpréter les prédictions du modèle avec des techniques d'explicabilité (XAI)

Les étapes réalisées dans ce projet :

1. Importation des bibliothèques :
2. Chargement et exploration des données

```
APERÇU DES DONNEES
=====
                                Review  Rating
0  nice hotel expensive parking got good deal sta...      4
1  ok nothing special charge diamond member hilt...      2
2  nice rooms not 4* experience hotel monaco seat...      3
3  unique, great stay, wonderful time hotel monac...      5
4  great stay great stay, went seahawk game aweso...      5
=====

INFORMATIONS GENERALES
=====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20491 entries, 0 to 20490
Data columns (total 2 columns):
#   Column  Non-Null Count  Dtype
---  -
0   Review  20491 non-null    object
1   Rating  20491 non-null    int64
dtypes: int64(1), object(1)
memory usage: 320.3+ KB
None

VALEURS MANQUANTES
=====
Review      0
Rating      0
dtype: int64

=====
STATISTIQUES DESCRIPTIVES
=====
count      20491.000000
mean         3.952223
std          1.233030
min           1.000000
25%           3.000000
50%           4.000000
75%           5.000000
max           5.000000
Name: Rating, dtype: float64

DISTRIBUTION DES NOTES
=====
Note 1: 1421 avis (6.9%)
Note 2: 1793 avis (8.8%)
Note 3: 2184 avis (10.7%)
Note 4: 6039 avis (29.5%)
Note 5: 9054 avis (44.2%)
```


➤ Interprétation :

Le jeu de données contient 20 491 avis clients, avec deux colonnes : "Review" de type texte et "Rating" de type entier.

Aucune valeur manquante n'est présente, ce qui facilite le traitement. Les premiers avis montrent une grande variété de longueurs et de styles, allant d'avis courts à des commentaires plus détaillés.


La distribution des notes révèle un fort déséquilibre. Les notes 4 et 5 dominent largement avec respectivement 29,5% et 44,2% des avis, soit près des trois quarts du total. À l'inverse, les notes 1 et 2 sont minoritaires avec seulement 6,9% et 8,8%. La note 3 occupe une position intermédiaire avec 10,7%. Cette répartition asymétrique est typique des plateformes d'avis en ligne, les clients satisfaits étant plus motivés à laisser un commentaire que les clients insatisfaits. Ce déséquilibre devra être pris en compte lors de la modélisation pour éviter que le modèle ne favorise les classes majoritaires.

3. Analyse exploratoire des données (EDA)



➤ Interprétation :

Le graphique montre un fort déséquilibre entre les classes : les notes 4 et 5 représentent ensemble 73,7% des avis, tandis que les notes 1 et 2 ne représentent que 15,7%. La note 5 est la plus fréquente avec 44,2%, suivie de la note 4 avec 29,5%. Ce déséquilibre est classique sur les plateformes d'avis, les clients satisfaits étant plus enclins à laisser un commentaire que les clients insatisfaits. Cette répartition devra être prise en compte lors de la modélisation pour éviter que le modèle ne favorise les notes élevées.



➤ Interprétation :

Le graphique montre que les avis les plus négatifs sont également les plus longs. Les notes 1 et 2 présentent des longueurs médianes plus élevées ainsi qu'une plus grande dispersion, avec des avis pouvant dépasser 1500 mots. À l'inverse, les notes 4 et 5 sont associées aux avis les plus courts, avec une médiane plus basse et peu de valeurs extrêmes. La note 3 se situe dans une position intermédiaire. Cette tendance s'explique par le fait que les clients insatisfaits éprouvent le besoin de détailler leurs problèmes et frustrations, tandis que les clients satisfaits expriment leur contentement de manière plus concise et directe.

STATISTIQUE DE LONGUEUR DES AVIS

	count	mean	std	min	25%	50%	75%	max
Rating								
1	1421.0	112.365236	99.834855	12.0	51.0	82.0	137.0	954.0
2	1793.0	126.601227	108.269031	10.0	63.0	95.0	148.0	1109.0
3	2184.0	114.705586	109.023017	9.0	54.0	86.0	134.0	1931.0
4	6039.0	107.771651	107.132817	9.0	49.0	78.0	128.0	1458.0
5	9054.0	93.963773	90.977999	7.0	44.0	69.0	111.0	1755.0

➤ Explication :

Le tableau confirme que les avis négatifs sont plus longs que les avis positifs. La note 2 a la moyenne la plus élevée avec 126,6 mots, suivie de la note 3 avec 114,7 mots et de la note 1 avec 112,4 mots. La note 5 a la moyenne la plus basse avec seulement 94 mots. On observe également que les avis de note 2 présentent l'écart-type le plus élevé (108,3), ce qui indique une grande variabilité dans la

Mots fréquents dans les avis NÉGATIFS (notes 1-2)



Ce graphique montre les mots les plus fréquents dans les avis clients. Le mot "staff" apparaît le plus souvent avec 100% de fréquence, suivi de "time" avec 95%, "people" avec 90% et "place" avec 85%. On retrouve également des mots comme "room" (65%), "water" (30%), "restaurant" (25%) et "problem" (10%). Ces résultats indiquent que les clients mentionnent principalement le personnel, le temps d'attente, l'ambiance, l'emplacement et les chambres dans leurs avis. Les mots négatifs comme "problem" apparaissent moins fréquemment, ce qui confirme la dominance des avis positifs dans le dataset.

4. Prétraitement des données

```
Exemple de nettoyage :
-----
AVANT : nice hotel expensive parking got good deal stay hotel anniversary, arrived late evening took advice previous
APRES : nice hotel expensive parking got good deal stay hotel anniversary arrived late evening took advice previous

=====
VECTORISATION TF-IDF
=====
Calcul de la matrice TF-IDF...
Matrice TF-IDF créée : 20491 échantillons, 5000 features
Variable cible : 5 classes (0 à 4)

Exemples de features (mots) : ['able' 'able check' 'able walk' 'absolute' 'absolutely'
'absolutely beautiful' 'absolutely loved' 'absolutely wonderful' 'ac'
'accept' 'acceptable' 'accepted' 'access' 'accessible' 'accommodate'
'accommodating' 'accommodation' 'accommodations' 'accomodate'
'accomodating']

-----
SePARATION TRAIN/TEST
=====
Ensemble d'entraînement : 16392 échantillons
Ensemble de test : 4099 échantillons

Distribution des classes - Entraînement :
Classe 0 (note 1): 1137 (6.9%)
Classe 1 (note 2): 1434 (8.7%)
Classe 2 (note 3): 1747 (10.7%)
Classe 3 (note 4): 4831 (29.5%)
Classe 4 (note 5): 7243 (44.2%)

Distribution des classes - Test :
Classe 0 (note 1): 284 (6.9%)
Classe 1 (note 2): 359 (8.8%)
Classe 2 (note 3): 437 (10.7%)
Classe 3 (note 4): 1208 (29.5%)
Classe 4 (note 5): 1811 (44.2%)
```

➤ Interprétation :

Le nettoyage des avis a bien fonctionné. On constate que la version nettoyée a perdu la ponctuation (virgules) et les espaces multiples, tout en conservant l'intégralité des mots importants. Par exemple, "arrived late evening took advice previous" est devenu plus propre sans perdre son sens.

La vectorisation TF-IDF a généré une matrice de 20 491 échantillons et 5 000 features (mots et bigrammes). Les features incluent des mots simples comme "able", "access", "clean", mais aussi des expressions comme "absolutely beautiful", "absolutely loved" et "absolutely wonderful". Ces bigrammes sont intéressants car ils capturent mieux le sentiment que les mots seuls.

La séparation entre ensemble d'entraînement (16 392 avis) et ensemble de test (4 099 avis) respecte parfaitement la proportion de chaque note. La stratification a bien fonctionné puisque les pourcentages sont identiques dans les deux ensembles : 6,9% pour la note 1, 8,7% pour la note 2, 10,7% pour la note 3, 29,5% pour la note 4 et 44,2% pour la note 5. Cette répartition permettra d'évaluer le modèle de manière fiable.

5. Modélisation :

```
ENTRAINEMENT DES MODELES
=====

Entraînement de Régression Logistique
+ Accuracy entraînement : 0.7366
+ Accuracy test : 0.6111
+ F1-score (weighted) : 0.5879

Entraînement de Random Forest
+ Accuracy entraînement : 1.0000
+ Accuracy test : 0.5526
+ F1-score (weighted) : 0.4895

Entraînement de XGBoost
+ Accuracy entraînement : 0.9222
+ Accuracy test : 0.5989
+ F1-score (weighted) : 0.5807
```

➤ Explication :


Les trois modèles montrent des signes de surapprentissage, avec des écarts importants entre les performances en entraînement et en test. La régression logistique est la plus stable avec 73,7% en entraînement et 61,1% en test, soit un écart de 12,6 points. Le F1-score de 58,8% indique une performance correcte mais perfectible.

La forêt aléatoire présente le surapprentissage le plus marqué avec 100% en entraînement mais seulement 55,3% en test, soit un

écart de 44,7 points. Elle mémorise parfaitement les données d'entraînement mais généralise mal.

XGBoost se situe entre les deux avec 92,2% en entraînement et 59,9% en test, soit un écart de 32,3 points. Bien que moins surappris que la forêt aléatoire, il n'atteint pas la stabilité de la régression logistique.

La régression logistique est donc le modèle à privilégier pour ce problème, car elle offre le meilleur compromis entre performance et généralisation.



➤ **Interprétation :**

La régression logistique est le modèle le plus performant avec une accuracy de 62% et un F1-score de 59% en test. Elle présente l'écart le plus faible entre l'entraînement (75%) et le test (62%), ce qui indique une bonne capacité de généralisation sans surapprentissage excessif. XGBoost obtient des résultats proches avec 60% d'accuracy et 59% de F1-score en test, mais l'écart important avec ses performances en entraînement (92%) révèle un surapprentissage plus marqué. La forêt aléatoire est la moins performante avec seulement 56% d'accuracy et 51% de F1-score en test, et son score parfait en entraînement (99%) confirme un surapprentissage sévère. En conclusion, la régression logistique est le modèle à retenir pour ce projet.

```
MEILLEUR MODELE : Régression Logistique
F1-Score : 0.5879
```

6. Évaluation détaillée du meilleur modèle


EVALUATION DETAILLEE - MEILLEUR MODELE

RAPPORT DE CLASSIFICATION

	precision	recall	f1-score	support
Note 1 (Tres mauvais)	0.71	0.66	0.68	284
Note 2 (Mauvais)	0.46	0.29	0.36	359
Note 3 (Moyen)	0.48	0.19	0.27	437
Note 4 (Bon)	0.51	0.49	0.50	1208
Note 5 (Excellent)	0.68	0.85	0.75	1811
accuracy			0.61	4099
macro avg	0.57	0.50	0.51	4099
weighted avg	0.59	0.61	0.59	4099

➤ Explication :

Le modèle performe bien sur les notes extrêmes avec un F1-score de 68% pour la note 1 et 75% pour la note 5, cette dernière bénéficiant d'un excellent rappel de 85%. En revanche, les notes intermédiaires sont mal prédites, notamment la note 3 avec un F1-score de seulement 27% et un rappel de 19%, ce qui s'explique par la frontière floue entre ces catégories et le déséquilibre des classes. La moyenne pondérée globale atteint 59%, une performance correcte pour ce type de classification textuelle.



➤ Interprétation :

La matrice de confusion confirme les difficultés du modèle sur les notes intermédiaires. La note 5 est la mieux classifiée avec 1534 prédictions correctes sur 1811 avis réels, soit un taux de bonne classification d'environ 85%. La note 1 obtient également un bon résultat avec 188 bonnes prédictions sur 284. En revanche, la note 3 est très mal classifiée : seulement 82 avis sur 437 sont correctement prédits. La plupart des avis de note 3 sont confondus avec les notes 4 (209 erreurs) et 5 (89 erreurs). De même, la note 2 est souvent confondue avec la note 1 (65 erreurs), la note 4 (85 erreurs) et la note 5 (59 erreurs). La note 4 est partagée entre la classe 4 (596 bonnes prédictions) et la classe 5 (564 erreurs), ce qui montre une hésitation constante entre ces deux notes. Ces résultats illustrent la difficulté à distinguer les avis mitigés des avis positifs.

ANALYSE PAR CLASSE

Classe 1 (Note 1):

Precision: 0.7068 | Rappel: 0.6620 | F1: 0.6836

Classe 2 (Note 2):

Precision: 0.4605 | Rappel: 0.2925 | F1: 0.3578

Classe 3 (Note 3):

Precision: 0.4795 | Rappel: 0.1876 | F1: 0.2697

Classe 4 (Note 4):

Precision: 0.5085 | Rappel: 0.4934 | F1: 0.5008


Classe 5 (Note 5):

Precision: 0.6782 | Rappel: 0.8470 | F1: 0.7533

➤ Explication :

Les notes extrêmes sont les mieux gérées par le modèle. La note 5 obtient un excellent rappel de 84,7% et un F1-score de 75,3%, ce qui signifie que le modèle identifie très bien les avis excellents. La note 1 suit avec un F1-score de 68,4% et une précision de 70,7%. À l'inverse, les notes intermédiaires sont très mal classifiées. La note 3 a le plus mauvais score avec un rappel de seulement 18,8% et un F1-score de 27%, ce qui indique que le modèle ne parvient quasiment pas à identifier les avis moyens. La note 2 n'est pas mieux avec un rappel de 29,3% et un F1-score de 35,8%. La note 4 obtient des résultats médiocres avec un F1-score de 50,1%. Ces résultats confirment que le modèle a du mal à distinguer les nuances entre les notes moyennes et les notes élevées.

7. Explicabilité du modèle (XAI)



➤ Interprétation :

Les mots "excellent", "ok", "perfect", "great" et "good" sont les plus importants pour le modèle, car leur suppression dégrade le plus les performances. Les mots positifs dominent largement ce classement. On retrouve également l'expression "great hotel" ainsi que "clean" et "friendly" qui sont des indicateurs de satisfaction. Les mots négatifs sont peu présents, à l'exception de "problem" et "tiny". Cela confirme que le modèle s'appuie principalement sur les termes positifs pour faire ses prédictions, ce qui explique sa bonne performance sur les notes élevées.

```
Top 10 des features par permutation importance
1. 'excellent' : 0.0051
2. 'ok' : 0.0051
3. 'perfect' : 0.0051
4. 'great' : 0.0050
5. 'good' : 0.0049
6. 'wonderful' : 0.0048
7. 'great hotel' : 0.0034
8. 'hotel' : 0.0030
9. 'bit' : 0.0030
10. 'tiny' : 0.0026
```

➤ Explication :

Les mots les plus importants sont "excellent", "ok", "perfect", "great" et "good" avec des valeurs très proches autour de 0,005. Le mot "ok" surprend car il peut exprimer une satisfaction modérée ou une déception polie selon le contexte. L'expression "great hotel" apparaît également avec une importance de 0,0034. Les mots "bit" et "tiny" sont les seuls termes potentiellement négatifs dans ce top 10, avec une importance plus faible de 0,0030 et 0,0026. Ce classement confirme que le modèle s'appuie principalement sur un vocabulaire positif pour classer les avis, ce qui explique sa bonne performance sur les notes élevées mais aussi ses difficultés à distinguer les notes moyennes.

8. Analyse locale - Exemples individuels

8.1 SELECTION D'EXEMPLES

AVIS POSITIF (Note 5) :

Aperçu : unique, great stay, wonderful time hotel monaco, location excellent short stroll main downtown shopping
Note réelle : 5

AVIS NÉGATIF (Note 1) :

Aperçu : horrible customer service hotel stay february 3rd 4th 2007my friend picked hotel monaco appealing websi
Note réelle : 1

AVIS MOYEN (Note 3) :

Aperçu : nice rooms not 4* experience hotel monaco seattle good hotel n't 4* level.positives large bathroom medi
Note réelle : 3

PREDICTION ET ANALYSE

ANALYSE DE L'AVIS POSITIF

AVIS ANALYSE :

Note réelle : 5

Note prédite : 5

Probabilités par classe :

Note 1: 0.0049

Note 2: 0.0108

Note 3: 0.0371

Note 4: 0.2612

Note 5: 0.6860

ANALYSE DE L'AVIS NEGATIF

AVIS ANALYSE :

Note réelle : 1

Note prédite : 1

Probabilités par classe :

Note 1: 0.5625

Note 2: 0.3264

Note 3: 0.0211

Note 4: 0.0514


Note 5: 0.0386

```

ANALYSE DE L'AVIS MOYEN
-----

AVIS ANALYSE :
Note réelle : 3
Note prédite : 4
Probabilités par classe :
Note 1: 0.1097
Note 2: 0.2148
Note 3: 0.0842
Note 4: 0.4233
Note 5: 0.1680

```



➤ **Interprétation :**

Pour l'avis positif (note 5 réelle), le modèle lui attribue une probabilité de 57% pour la note 2, 26% pour la note 4 et 10% pour la note 1. Il ne parvient pas à reconnaître correctement cet avis comme excellent.

Pour l'avis négatif (note 1 réelle), le modèle lui donne 68% de probabilité pour la note 3, 56% pour la note 5 et 57% pour la note 1. Les probabilités sont réparties entre plusieurs classes, ce qui montre une grande incertitude.

Pour l'avis moyen (note 3 réelle), le modèle lui attribue 43% pour la note 2, 19% pour la note 5 et 18% pour la note 3. Là encore, le modèle hésite fortement.

Ces résultats confirment que le modèle a du mal à classer correctement les avis, en particulier ceux qui ne sont pas clairement très positifs ou très négatifs. Les probabilités sont souvent éparpillées entre plusieurs notes.

9. Synthèse et visualisation finale

RESUME DES PERFORMANCES

Régression Logistique:

Accuracy Test : 0.6111

F1-Score Test : 0.5879

XGBoost:

Accuracy Test : 0.5989

F1-Score Test : 0.5807

Random Forest:

Accuracy Test : 0.5526

F1-Score Test : 0.4895

TOP 10 MOTS PAR CLASSE

Note 1 :

- 'not' (3781 occurrences)
- 'hotel' (3608 occurrences)
- 'room' (3285 occurrences)
- 'nt' (1676 occurrences)
- 'no' (1572 occurrences)
- 'did' (1312 occurrences)
- 'stay' (1209 occurrences)
- 'staff' (961 occurrences)
- 'night' (903 occurrences)
- 'rooms' (902 occurrences)

Note 2 :

- 'not' (5213 occurrences)
- 'room' (4265 occurrences)
- 'hotel' (4191 occurrences)
- 'nt' (2360 occurrences)
- 'no' (1976 occurrences)

Note 3 :


- 'hotel' (5067 occurrences)
- 'not' (4738 occurrences)
- 'room' (4444 occurrences)
- 'nt' (2592 occurrences)
- 'good' (2463 occurrences)
- 'did' (1927 occurrences)
- 'great' (1754 occurrences)
- 'nice' (1747 occurrences)
- 'no' (1649 occurrences)
- 'rooms' (1486 occurrences)

Note 4 :

- 'hotel' (14163 occurrences)
- 'room' (10199 occurrences)
- 'not' (8833 occurrences)
- 'great' (7436 occurrences)
- 'good' (6707 occurrences)
- 'nt' (5958 occurrences)
- 'nice' (4831 occurrences)
- 'staff' (4676 occurrences)

Note 5 :

- 'hotel' (21891 occurrences)
- 'room' (12154 occurrences)
- 'great' (10678 occurrences)
- 'not' (8962 occurrences)
- 'staff' (7818 occurrences)
- 'stay' (6832 occurrences)
- 'nt' (6414 occurrences)
- 'good' (5722 occurrences)
- 'just' (5164 occurrences)
- 'location' (4827 occurrences)



➤ Interprétation :

Le graphique des F1-scores par modèle confirme que la régression logistique est le meilleur modèle avec un score d'environ 0,62, suivie de XGBoost avec 0,60 et de la forêt aléatoire avec environ 0,56. La régression logistique offre le meilleur compromis entre performance et généralisation.

La matrice de confusion normalisée de la régression logistique montre que la note 5 est la mieux classifiée avec 85% de bonnes prédictions. La note 1 suit avec 66%. En revanche, la note 3 n'est correctement classifiée qu'à 19%, et elle est souvent confondue avec la note 4 (48% des cas). La note 4 est partagée entre la classe 4 (49%) et la classe 5 (47%). La note 2 est également mal classifiée avec seulement 29% de bonnes prédictions, souvent confondue avec les notes 1, 3 et 4.

Ces résultats confirment que le modèle réussit bien sur les avis extrêmes mais peine à distinguer les avis mitigés des avis positifs. Cette limite est principalement due au déséquilibre des classes et à la frontière floue entre les notes 3, 4 et 5.

Conclusion :

Ce projet visait à analyser des avis clients TripAdvisor pour prédire les notes hôtelières. Trois modèles ont été testés : la régression logistique, la forêt aléatoire et XGBoost. La régression logistique est le meilleur modèle avec une accuracy de 62% et un F1-score de 59% en test, offrant le meilleur compromis entre performance et généralisation.

Les mots les plus influents sont "excellent", "perfect", "great" et "good" pour les notes élevées. Le modèle performe bien sur les notes extrêmes (F1-scores de 68% pour la note 1 et 75% pour la note 5), mais rencontre des difficultés sur les notes intermédiaires, notamment la note 3 avec un faible F1-score de 27%.

Les principales limites sont le déséquilibre des classes et la difficulté à distinguer les avis mitigés. Des améliorations possibles incluent l'utilisation de BERT pour mieux capturer le contexte et des techniques de rééquilibrage pour mieux prédire les classes minoritaires.